



FM의 RAG 활용

2026

6. 지식 그래프 이해

- **그래프와 지식그래프**

- 그래프(Graph) 자료구조: 노드(Node/Entity) + 엣지(Edge/Relationship)로 데이터 간 관계를 표현
- 일반 그래프 vs 지식그래프(Knowledge Graph): 지식그래프는 노드/엣지에 의미(semantic) 라벨이 부여된 그래프
- 표(테이블) 형태의 한계: 행-열 구조로는 "A가 B를 유발하고 B가 C로 이어진다"는 다단계 관계 표현이 어려움
- 그래프 표현의 장점: 관계 자체가 1차 데이터(first-class data)가 되어 multi-hop 질의(예: "이 부품 문제가 최종적으로 어떤 불량까지 이어지는가")가 자연스러움
- 제조 도메인 동기: 설비→부품→센서이상→불량유형→원인→조치의 인과 연쇄는 표보다 그래프가 직관적

6. 지식 그래프 이해

- **제조 지식 그래프: 4M(Man, Machine, Material, Method)을 활용한 불량 관계 그래프**

- 4M 프레임워크: Man(작업자) · Machine(설비) · Material(원재료) · Method(작업방법) — 제조 품질관리 전통 원인 분류체계
- 그래프 노드 체계: 설비 → 부품 → 센서이상 → 불량유형 → 원인(4M 분류) → 조치
- 예시 경로:
 - "사출성형기#3" -[포함]→ "히터" -[이상징후]→ "온도편차" -[유발]→ "치수불량" -[원인분류]→ "Machine(설비노화)" -[조치]→ "히터교체"
- 장점: 유사한 불량 패턴을 가진 다른 설비/사례를 그래프 경로 탐색으로 빠르게 발견 가능Day3 실습 연계: 이 스키마가 그래프RAG 인덱싱의 기준 구조가 됨

7. Graph RAG 활용

- **Advanced RAG 파이프라인 구축: BM25+Dense Hybrid 검색**

- 구현 구조: BM25 검색기(키워드 기반) + Dense 검색기(임베딩 기반)를 병렬 실행 후 점수 결합
- RRF(Reciprocal Rank Fusion) 공식: $\text{score} = \sum 1/(k + \text{rank}_i)$
 - 각 검색기의 순위를 역수로 변환해 합산, 특정 검색기에 과도하게 의존하지 않는 장점
- LangChain 구현: BM25Retriever + EnsembleRetriever로 비교적 간단하게 구성 가능
- 가중치 조정: EnsembleRetriever(retrievers=[bm25, dense], weights=[0.4, 0.6])
 - 도메인 특성에 따라 튜닝
- 제조 도메인 효과: 설비코드·부품번호 같은 정확한 키워드는 BM25가, "진동이 심하고 소음이 발생하는 상황"처럼 서술형 증상은 Dense가 각각 담당해 검색 커버리지 확대

7. Graph RAG 활용

- **Advanced RAG 파이프라인 구축: Cross-Encoder Reranker 적용**

- 적용 위치: 1차 Hybrid 검색으로 Top-30~50 후보 추출 → Cross-Encoder로 재정렬 → 최종 Top-3~5만 LLM에 전달
- Cross-Encoder 동작: 질의+문서를 하나의 입력으로 concat해 관련도 점수(0~1) 직접 계산
- LangChain 구현: CrossEncoderReranker + ContextualCompressionRetriever로 파이프라인 삽입
- 속도 trade-off: 정밀도는 올라가지만 후보 수×인퍼런스 비용이 증가 → Top-K를 너무 크게 설정하지 않는 것이 중요
- Reranker 적용 전후 동일 질의에 대해 반환된 상위 문서 목록 비교를 통해 순위 변경 확인

7. Graph RAG 활용

- **MS의 Graph RAG 구조 분석**

- Microsoft GraphRAG: 문서에서 엔티티·관계를 자동 추출해 지식그래프를 구축하고, 이를 기반으로 검색하는 RAG 프레임워크
- 인덱싱 단계: LLM으로 문서 → 엔티티/관계 triple 추출 → 커뮤니티 탐지(Leiden 알고리즘)로 연관 클러스터링 → 커뮤니티별 요약 생성
- 두 가지 검색 모드:
 - Local Search: 특정 엔티티/관계 중심 세부 질의에 적합 (예: "3호기 베어링 불량 원인")
 - Global Search: 전체 문서셋의 주제·패턴 파악에 적합 (예: "전체 설비 불량 중 가장 빈번한 원인 유형은?")
- 벡터RAG와 차이: 벡터RAG는 지엽적 유사 문서 반환, GraphRAG는 문서 전체를 관통하는 관계·패턴 추론 가능
- 한계: LLM 기반 엔티티 추출 → 인덱싱 비용이 높고, 추출 품질이 베이스 LLM 성능에 의존

8. Advanced Vector RAG VS Graph RAG

- 두 RAG의 비교

- 검색 방식 / 문서 구조 이해 / 다단계 추론 / 인덱싱 비용 / 응답 적합 질의 유형 비교

항목	Advanced 벡터RAG	Graph RAG
검색 방식	임베딩 유사도 + BM25	그래프 경로 탐색 + 커뮤니티 요약
강점 질의	특정 문서 내용 찾기	다단계 인과관계, 전체 패턴 파악
다중 문서 추론	약함 (문서 간 관계 파악 어려움)	강함 (엔티티 간 관계 명시적 표현)
인덱싱 비용	낮음	높음 (LLM 기반 엔티티 추출)
최신 문서 반영	빠름	느림 (그래프 재구축 필요)

- 예: 개별 보고서 조회 → 벡터RAG, 불량 원인 연쇄 분석/설비 간 패턴 비교 → GraphRAG
- 두 방식은 경쟁 관계가 아니라 상호보완적 — 하이브리드 구성이 실무에서 현실적인 선택

8. Advanced Vector RAG VS Graph RAG

- RAGAS란?

- RAGAS(RAG Assessment):

- RAG 파이프라인을 자동으로 평가하는 오픈소스 프레임워크
 - 답 라벨이 있는 QA pair뿐 아니라, 정답 없이 질문-응답-context만으로도 평가할 수 있는 지표가 포함되어 있어 실무에서 자주 활용

- 4가지 핵심 지표:

- Faithfulness (충실성): 생성된 답변의 주장들이 검색된 context로 실제로 뒷받침되는지를 측정. 답변을 개별 claim 단위로 분해한 뒤, 각 claim이 context에서 추론 가능한지를 LLM이 판정 — 환각(hallucination) 탐지에 직결되는 지표.
 - Answer Relevancy (답변 관련성): 답변이 질문의 의도에서 벗어나지 않고 직접적으로 응답하는지를 측정. 생성된 답변으로부터 역으로 가상의 질문들을 만들어 원 질문과의 임베딩 유사도를 비교하는 방식.

8. Advanced Vector RAG VS Graph RAG

- RAGAS란?

- 4가지 핵심 지표:

- Context Recall (문맥 재현율): 정답(ground truth)을 생성하는 데 필요한 정보가 검색된 context 안에 빠짐없이 포함되어 있는지 측정 — 검색기(retriever)의 "놓침" 여부를 잡아냄. 정답 라벨이 있어야 계산 가능.

- Context Precision (문맥 정밀도): 검색된 여러 context 중 실제로 답변 생성에 유용했던 것의 비율 — 검색기가 불필요한 노이즈를 얼마나 끌고 오는지를 잡아냄.

- 평가 흐름: QA pair(질문 + 정답) + RAG가 생성한 응답 + 검색된 context 묶음을 RAGAS에 입력 → 각 지표별로 0~1 사이 점수 산출 → 평균 내어 파이프라인 전체 품질을 정량화.

- LLM-as-Judge 연계: RAGAS는 내부적으로 LLM을 "심사위원"으로 호출해 각 지표를 계산. 기본값은 OpenAI 계열이지만, Ollama로 로컬 LLM(Qwen, Gemma 등)을 judge로 붙이는 것도 가능

- 예: 10~20개 QA pair 샘플에 대한 Faithfulness 점수 산출

- RAG ?

- 흩어진 데이터를 연결해 LLM이 판단하는 DSS



Mission 1

ChromaDB RAG

비정형 매뉴얼·보고서 검색



Mission 2

3-Tool Agent

RAG + DuckDB + 웹검색 결합



Mission 3

LangGraph

분류 → 라우팅 → 처리 자동화

이 구조가 실제 제조 현장에서는 어떤 모습?

- **CASE 01 · 설비 진단**

- 현장:


- 설비 이상 발생 시 작업자가 두꺼운 매뉴얼을 직접 뒤져야 함
 - 동일 증상이 과거 정비이력에 이미 있는지 알 수 없음
 - 숙련공의 암묵지가 퇴직과 함께 사라짐

- 적용

- 매뉴얼(PDF) → RAG로 절차/스펙 검색
 - 정비 로그(DB) → 유사 고장이력 질의
 - 두 결과를 종합해 원인 후보와 조치를 함께 제시

• CASE 02 · 품질 분석

- 불량 보고서 RAG + DB 기반 원인분석



- 중대 불량은 사람 검토로, 경미한 반복 불량은 자동 RCA 초안 생성 — 라우팅이 곧 업무 분배
- 같은 불량 패턴이 다른 라인/설비에서도 반복되는지 확인 가능

Mission 3의 classify → 조건부 라우팅 구조가 '경미/중대 불량 분기'에 적용

• CASE 03 · 예지보전



자연어 → SQL 질의

"최근 3개월간 모터 베어링 교체가 잦은 설비 Top 5는?" 같은 질문을 NL-to-SQL 도구가 즉시 DuckDB 질의로 변환




외부 정보 결합

교체가 필요한 부품의 최신 가격·리드타임·대체품 정보를 웹 검색 도구로 함께 조회 → 구매 의사결정까지 확장

• 중요성

- 고장 후 정비(reactive) → 고장 전 예측(predictive)으로 전환
- 비계획 정지(downtime) 비용을 직접 절감
- 정비 인력의 경험치를 데이터 자산으로 전환

- RAG 사례 1: Siemens



- Siemens 에를랑겐 전자공장(Electronics Factory Erlangen)
 - Siemens Industrial Copilot — 24/7 현장 트러블슈팅
- 현장 작업자가 챗봇 인터페이스로 설비 구성·문제해결·복구까지 24시간 지원받음
- Simatic eaSie — 채팅/음성으로 플랜트·설비 데이터 접근 (프로세스 산업용)
- Microsoft Azure AI 기반 공동 개발

- RAG 사례 2: Siemens

Siemens introduces AI agents for industrial automation

- Automating automation: AI agents enhancing Siemens Industrial Copilots
- Future vision: ecosystem of Industrial AI agents available on the Siemens Xcelerator platform with both Siemens and third-party AI agents
- Productivity aimed to increase by up to 50% for industrial companies



At Automate 2025 in Detroit, Siemens is announcing an expansion of its industrial AI offerings with advanced AI agents designed to work seamlessly across its established Industrial Copilot ecosystem. This new technology represents a fundamental shift from AI assistants that respond to queries towards truly autonomous agents that proactively execute entire processes without human intervention. Siemens' new AI agent architecture features a sophisticated orchestrator. Like a craftsman, it deploys a toolbox of specialized agents to solve complex tasks across the entire industrial value chain. These agents work intelligently and autonomously – understanding intent, improving performance through continuous learning, and accessing external tools and other agents as needed. Users retain complete control, selecting which tasks they wish to delegate to AI agents.

- Siemens Senseye
 - Predictive Maintenance Copilot / 정비 효율화
 - 반응형 정비(reactive) → 예방 → 예측 → 최적화까지 정비 전 주기 지원
 - 파일럿 적용 결과 반응형 정비 소요시간 평균 25% 감소
 - Sachsenmilch (유럽 최대 유제품 기업 중 하나)에도 적용: 이기종 생산설비 인프라에 적용

- RAG만으로 충분?

RAG가 잘하는 것

- 질의와 '의미적으로 비슷한' 문서 조각 찾기
- 하나의 문서 안에서 답이 명확한 질문

RAG가 못하는 것

- 이 설비 — 이 부품 — 이 공급사 간의 '관계' 추적
- 여러 문서에 흩어진 사실을 종합해 추론

예시 질문

"이 부품을 쓰는 다른 설비에서도 같은 불량이 발생했나?"

벡터 검색은 '비슷한 문장'은 찾지만, 부품→설비→불량으로 이어지는 '연결고리'는 알지 못함

이 질문에 답하려면 개체 간 관계를 구조화한 지식이 필요

- RAG만으로 충분?

- 산업 현장 RAG 도입 실태: 13개 기업 인터뷰 연구, 2025년 8월
 - 대부분 도메인 특화 QA 수준, 아직 프로토타입 단계
 - 기업들은 환각(hallucination) 우려로 신중하게 단계적 도입 중

Retrieval-Augmented Generation in Industry: An Interview Study on Use Cases, Requirements, Challenges, and Evaluation

Lorenz Brehme¹^a, Benedikt Dornauer¹^b, Thomas Ströhle¹^c,
Maximilian Ehrhart²^d, Ruth Breu¹^e

¹University of Innsbruck, Innsbruck, Austria

²CASABLANCA hotelsoftware, Schönowies, Austria

{lorenz.brehme, benedikt.dornauer, thomas.stroehle, ruth.breu}@uibk.ac.at, maximilian.ehrhart@casablanca.at


Keywords: Retrieval Augmented Generation, Industrial Application, Interview Survey

Abstract: Retrieval-Augmented Generation (RAG) is a well-established and rapidly evolving field within AI that enhances the outputs of large language models by integrating relevant information retrieved from external knowledge sources. While industry adoption of RAG is now beginning, there is a significant lack of research on its practical application in industrial contexts. To address this gap, we conducted a semi-structured interview study with 13 industry practitioners to explore the current state of RAG adoption in real-world settings. Our study investigates how companies apply RAG in practice, providing (1) an overview of industry use cases, (2) a consolidated list of system requirements, (3) key challenges and lessons learned from practical experiences, and (4) an analysis of current industry evaluation methods. Our main findings show that current RAG applications are mostly limited to domain-specific QA tasks, with systems still in prototype stages; industry requirements focus primarily on data protection, security, and quality, while issues such as ethics, bias, and scalability receive less attention; data preprocessing remains a key challenge, and system evaluation is predominantly conducted by humans rather than automated methods.

This preprint was accepted for presentation at the 17th International Conference on Knowledge Discovery and Information Retrieval (KDIR25).

- 온톨로지(Ontology)


- 데이터를 '문서 더미'가 아니라 개체(Entity)-관계(Relationship)-속성(Attribute)의 그래프로 모델링



RAG vs 온톨로지

- RAG = 도서관에서 키워드로 비슷한 책을 빨리 찾아주기
- 온톨로지 = 책들 사이의 인용 관계, 저자 관계까지 미리 정리해둔 '지식의 지도'

- GraphRAG — RAG와 온톨로지를 연결




LightRAG: '키워드 매칭'에서 '관계 추론'

제조 현장 적용 예


설비-부품-불량유형-원인 그래프를 만들면 "이 부품을 쓰는 다른 설비에서도 같은 문제가 생길까?" 같은 질문에 대응

- GraphRAG — 제조 문서 적용 사례



- 기존 : 설비 문제 해결을 위해 엔지니어가 수천 건의 정비 매뉴얼·트러블슈팅 가이드·부품 카탈로그를 직접 검색하거나 전문가에게 문의
- 내용: 전통적 키워드 검색 + 수작업 전문가 상담 체계를 GraphRAG 기반 시스템으로 전환
- Microsoft GraphRAG 프레임워크 활용 구축: 약 6개월 (여러 레거시 시스템에서 데이터 마이그레이션 + 설비 계층구조·부품 관계에 대한 커스텀 엔티티 추출 포함)
- 핵심 성과: 기술 이슈 평균 해결 시간이 3.2시간에서 1.7시간으로, 47% 단축

• 팔란티어(Palantir) Foundry / AIP 사례



핵심 개념: 디지털 트윈 온톨로지

설비, 작업자, 주문, 부품 같은 실세계 자산을 객체(Object)로 디지털화하고, 그 위에 LLM 에이전트를 얹어 단순 질의응답을 넘어 '행동(Action)'까지 연결

적용 패턴

항공·에너지 등 중공업 분야에서 부품 추적, 정비 최적화, 공급망 시뮬레이션에 온톨로지 기반 플랫폼이 활용

Closed-Loop 구조

- 1 이상 탐지 (Detect)
- 2 원인 추론 (Reason)
- 3 작업지시 생성 (Act)
- 4 결과 피드백 (Learn)

- 팔란티어(Palantir) Foundry / AIP 사례

장갑차 새시 조립 시 용접 공정에 AIP를 적용: 센서에서 실시간 데이터를 수집, '의사결정 중심 온톨로지(decision-centric ontology)'로 발전, 예지보전과 실시간 공정 조정이 표준 프로토콜이 되는 동적인 제조 환경



Foundry: 기업용 데이터 통합 플랫폼

AIP: Artificial Intelligence Platform, 2023년에 출시한 플랫폼, 엔터프라이즈 보안 통제를 유지하면서 대규모 언어모델을 통합), 파운드리 위에 LLM 레이어

- 현대 중공업

조선업 분야, 4,500만 달러 이상 규모 파트너십

 Palantir [Investor Relations]

[News](#) / [Events](#) / [Financials](#) / [Governance](#) / [Resources](#)

01 / 20 / 2026

HD Hyundai and Palantir Expand Group-Wide Strategic Partnership

SEOUL, South Korea & DENVER—(BUSINESS WIRE)— HD Hyundai and Palantir Technologies Inc. have strengthened their alliance by reinforcing the strategic partnership. This alliance represents the largest and longest partnership of its kind for Palantir in Korea, significantly expanding the adoption of Palantir's Foundry and Artificial Intelligence Platform (AIP) across the HD Hyundai Group.

The partnership builds on a successful track record that began in 2021 with HD Hyundai Oilbank and expanded to shipbuilding and construction equipment subsidiaries, where Foundry and AIP are already at the core of their connected refinery, strengthening the foundation for the Future of Shipyard, and accelerating the development of construction equipment. The partnership has already delivered tangible results in refinery operations, crude oil selection, predictive maintenance, and sensor data analysis at HD Hyundai Oilbank. In shipbuilding, the collaboration is driving the Future of Shipyard initiative. Palantir's platforms are positioned as the orchestration layer, complementing digital twin and 3D modeling efforts led by other technology partners.

• RAG vs 온톨로지/그래프

상황	권장 접근	이유
단일 문서 내 질의응답 (매뉴얼, SOP 검색)	RAG	빠르고 구축 비용이 낮음, 오늘 Mission 1 수준
정형 + 비정형 결합 질의 (로그+매뉴얼)	RAG + Agent	도구 결합으로 충분, Mission 2 수준
개체 간 관계 추적 (부품↔설비↔불량 이력)	GraphRAG / 온톨로지	벡터 유사도로는 관계 추론 불가
탐지부터 실행까지 자동화 (작업지시, 알림 연동)	온톨로지 + Agent	단순 응답이 아닌 행동 연계 필요

• 실무 적용 가이드



• 도입 시 주의점

1

그래프부터 설계하려는 욕심

처음부터 완벽한 온톨로지를 설계하려다 프로젝트가 출시 전에 난관 RAG로 시작해 필요할 때 확장

2

평가 체계 부재

ragas / 수동 평가 지표(Context Recall, Faithfulness)처럼 정량 기준 필요

3

모델 크기와 추출 품질 착각

작은 모델(예: gemma:2b 급)은 구조화된 관계 추출을 안정적으로 못하는 한계

Industrial Data Science Lab

Contact:

won.sang.l@kangwon.ac.kr

<https://sites.google.com/view/idslab>